

A. Consejos y Buenas Prácticas para el Desarrollo del Taller

Guía basada en la experiencia acumulada de diferentes ejercicios alrededor de estos datos. Úsenla como guía a lo largo de su propio proceso, no como una lista para revisar al final.

Entendimiento de los Datos y del Negocio

Confirmen la unidad de medida de cada variable antes de interpretarla o usarla

Por qué importa: Una suposición razonable sobre unidades, sin confirmarla, puede llevarlos a una interpretación completamente errónea. Un ejemplo real de esto: la variable Vejez parece, por el contexto del ciclo de maduración (12-18 meses), que debería estar en meses o semanas. En realidad está en **horas**, y representa el tiempo entre el corte (o una quema accidental) y la llegada al molino. En operación normal ese valor es menor a 10 horas; valores como "73 horas" reflejan eventos atípicos de quema accidental antigua, no un error de escala.

Recomendación: Para cada variable numérica ambigua, revisen el rango de valores (describe()) y pregúntense si ese rango es coherente con la unidad que ustedes suponen. Si el rango no calza con su hipótesis, esa es su señal de alarma para investigar más, no para forzar la interpretación que ya tenían en mente.

No asuman que un valor "raro" en una variable categórica es un error de captura

Por qué importa: Es tentador pensar que si Suelo muestra valores como "Génova" o "Yumbo" en vez de categorías esperadas tipo "arenoso" o "arcilloso", se trata de un error de imputación. En este caso específico, esos nombres corresponden a una **taxonomía de suelos diseñada específicamente por Cenicaña para el valle geográfico del río Cauca** — es información agronómica legítima y más granular de lo que parece a primera vista, no un error.

Recomendación: Antes de descartar o "corregir" una categoría que no entienden, investiguen si corresponde a una nomenclatura técnica del sector (Cenicaña es la fuente de referencia para gran parte de esta terminología). Documenten su hallazgo con el nivel de confianza correspondiente, tal como discutimos para el ejercicio del diccionario de datos.

Entiendan que las bases de datos agrícolas reales rara vez son perfectas — y eso no es excusa para ser descuidados, pero tampoco motivo de parálisis

Por qué importa: Ni siquiera el Ingenio tiene, a la fecha, un diccionario de datos completo ni una infraestructura de datos totalmente madura; sus datos climáticos, por ejemplo, se integran mediante conexión a una API externa (Cenicaña) y tienen vacíos de cobertura en ciertos periodos históricos. Esto es normal en un contexto real de ciencia de datos aplicada.

Recomendación: Documenten cada decisión de limpieza o imputación con su justificación razonada (aunque no sea una certeza absoluta), avancen con el modelado, y dejen constancia explícita de las limitaciones de los datos en su sección de conclusiones. Un informe que

documenta honestamente sus incertidumbres vale más que uno que aparenta una limpieza perfecta que en realidad no se puede verificar.

Análisis Exploratorio de Datos (EDA)

Analicen la relación entre sus DOS variables objetivo antes de modelar nada

Por qué importa: TCH (cantidad) y %Sac.Caña (calidad) son objetivos de negocio distintos y, agronómicamente, no siempre van de la mano. Asumir que "más caña" implica "más dulce" puede llevarlos a decisiones de negocio erróneas más adelante.

Recomendación: Calculen y visualicen la correlación entre TCH y %Sac.Caña como uno de sus primeros pasos de EDA. El resultado (probablemente una correlación baja o incluso negativa) debe guiar si tiene sentido compartir features/enfoque entre ambos modelos o tratarlos como problemas independientes desde el inicio.

No dejen la decisión sobre outliers "pendiente para después" — y no apliquen IQR de forma ciega

Por qué importa: Es tentador identificar outliers estadísticamente, documentarlos en el EDA y posponer la decisión sin volver nunca a cerrarla. Además, un límite matemático (como $1.5 \times \text{IQR}$) puede marcar como "atípico" algo que es perfectamente real en el contexto agronómico del Ingenio, o pasar por alto algo que sí es un error.

Recomendación: Usen criterio de negocio, no solo estadístico. Como referencia (validada por la representante del Ingenio):

- En TCH, valores entre 180-200 t/ha **no son atípicos**: corresponden a suertes orgánicas de alta productividad.
- Valores **superiores a 250 t/ha** sí son inusuales y ameritan revisión.
- Valores **inferiores a 50-60 t/ha** (ej. 6 t/ha) sí suelen ser atípicos: probablemente corresponden a cosechas de semilla mal registradas como cosecha comercial.
- Más de 20 cortes en una misma suerte **no es necesariamente un error**: existen zonas de manejo orgánico de alto rendimiento que no se renuevan por años.
- En variables climáticas (ej. lluvias anuales), un valor como ~1000 frente a un rango típico de 180-300 sí es un atípico genuino.

Para cada variable con outliers relevantes, respondan explícitamente antes de avanzar a modelado: ¿es un error de captura, un evento agronómico real, o simplemente la variabilidad natural del cultivo? Documenten la decisión final (conservar/transformar/eliminar).

No traten los extremos de su variable objetivo como "ruido a limpiar"

Por qué importa: Un histograma muy concentrado (ej. sacarosa entre 11-13%) puede tentarlos a describir el proceso como "estable" y minimizar los outliers. Pero justamente esos extremos suelen ser los lotes que el Ingenio más necesita identificar para actuar (los de desempeño excepcionalmente alto o bajo).

Pregunta para reflexionar: Si su objetivo final es ayudar al Ingenio a *alertar* sobre lotes críticos, ¿qué pasa con esa capacidad de alerta si tratan los valores extremos como algo a suavizar en vez de como la señal más valiosa del dataset?

No descarten una variable con fundamento agronómico fuerte solo porque su correlación lineal es baja

Por qué importa: La correlación de Pearson solo captura relaciones **lineales**. Puede existir una relación real y agronómicamente muy sólida (por ejemplo, entre lluvias y TCH/sacarosa) que el correlograma no refleje bien, simplemente porque la relación no es una línea recta. Además, una variable puede mostrar baja correlación en *este* dataset específico simplemente porque el rango de valores observado es demasiado homogéneo para que el efecto se manifieste (por ejemplo, la distancia entre la hacienda y el ingenio debería afectar la sacarosa por degradación durante el transporte, pero si en su ingenio todas las distancias son cortas y el transporte es rápido, ese efecto puede no verse reflejado en los datos).

Recomendación accionable: Antes de descartar una variable con justificación agronómica clara, exploren relaciones no lineales (promedios por bins de la variable objetivo, importancia en modelos de árboles, `mutual_info_regression/mutual_info_classif`). Si concluyen que "no importa", verifiquen primero que no sea simplemente un problema de rango restringido en sus datos, y digan esto explícitamente en su discusión.

Preprocesamiento

Nunca calculen estadísticos de imputación/escalado sobre el dataset completo antes de dividir train/test

Por qué importa: Calcular la media, mediana o cuartiles usando todas las filas (incluidas las que después serán su conjunto de prueba) es una forma sutil pero real de **fuga de información (data leakage)**. El modelo termina "viendo" indirectamente información del conjunto que se supone debe evaluarlo de forma independiente, y sus métricas de prueba dejan de ser confiables.

Recomendación accionable (pseudocódigo):

```
# Incorrecto: el imputador "ve" el dataset completo
```

```
media_global = df['col'].mean()
```

```
# Correcto: el imputador solo aprende del conjunto de entrenamiento
```

```
imputer.fit(X_train)
```

```
X_train_imputed = imputer.transform(X_train)
```

```
X_test_imputed = imputer.transform(X_test)    # jamás .fit() aquí
```

Este mismo principio aplica a la imputación de outliers, no solo a la de nulos. Empaqueten esta lógica dentro de un Pipeline/ColumnTransformer de sklearn desde el inicio; esto también les protege automáticamente durante la validación cruzada, donde cada fold debe recalcular sus propios estadísticos.

Usen Pipelines de sklearn desde el principio, no como un paso final de "limpieza de código"

Por qué importa: Un Pipeline con ColumnTransformer no es solo organización; es la forma más robusta de evitar fuga de información y de garantizar que su preprocesamiento se replique exactamente igual en entrenamiento, validación cruzada y prueba.

Recomendación: Diseñen su pipeline de preprocesamiento (imputación + escalado + encoding) antes de empezar a probar modelos, no lo construyan a posteriori. Esto también les ahorrará tiempo cuando lleguen a GridSearchCV.

No usen la misma estrategia de imputación para todas las variables sin pensar en el significado del vacío

Por qué importa: Imputar todo con la media/mediana/moda es más rápido, pero puede introducir sesgos importantes según lo que realmente signifique el dato faltante. Un caso confirmado directamente por el Ingenio: los espacios en blanco en la variable Producto (y ceros/vacíos relacionados en Dosis Madurante o Semanas mad.) **no son datos faltantes por error de captura** — significan que a esa suerte específicamente **no se le aplicó ningún madurante químico** (por manejo orgánico o por decisión del cañicultor). Esto es información predictiva valiosa: la ausencia de madurante está asociada a menor sacarosa.

Recomendación: Antes de elegir un método de imputación, pregúntense variable por variable qué significa realmente "sin dato" en ese contexto agronómico. Para casos como este, la imputación correcta es crear una categoría explícita (ej. "No aplicado"), **nunca eliminar la variable ni imputarla con un valor genérico que oculte esa información.**

Ingeniería de Características

El riesgo más importante del taller: variables derivadas del propio objetivo (data leakage)

Por qué importa: El dataset contiene variables como TCHM, TAH, TAHM, KATRHM, Rdto, %ATR, %Sac.Muestreadora, Brix, Pureza, que están matemáticamente ligadas o son derivadas de TCH y %Sac.Caña, y que además se miden **después de la cosecha o en el proceso fabril/de laboratorio** (esto ha sido confirmado directamente por el Ingenio: TCHM, por ejemplo, es literalmente "dividir el TCH en los meses de cosecha" — solo se conoce una vez cosechado; Brix se mide en fábrica). Si las incluyen como predictoras, van a obtener métricas espectaculares ($R^2 > 0.95$) que **no son reales**: no están anticipando el rendimiento antes de la cosecha, están usando información que solo existe después de que el evento ya ocurrió.

Recomendación: Antes de entrenar cualquier modelo, revisen cada variable candidata y pregúntense: *¿esta variable se conoce ANTES de la cosecha, o solo se mide/calcula DESPUÉS (en fábrica o laboratorio)?* Si la respuesta es "después", no puede ser predictora en un modelo diseñado para anticipar resultados. Traten un R^2 sospechosamente alto (>0.9) como una **señal de alarma a investigar**, nunca como un resultado a celebrar sin cuestionarlo primero.

Cuidado con variables categóricas de alta cardinalidad (ej. código de finca o lote) que terminan dominando el modelo

Por qué importa: Variables como el identificador de finca/lote pueden terminar "ganando" en importancia no porque capturen un fenómeno agronómico generalizable, sino porque el modelo aprende a memorizar el comportamiento histórico de cada lote específico. Esto se ve bien en validación cruzada (porque los mismos lotes aparecen en train y test), pero generaliza mal frente a un lote nuevo.

Pregunta para reflexionar: Si tuvieran que aplicar su modelo a un lote completamente nuevo, ¿seguiría siendo útil una variable que esencialmente codifica "cuál lote es"? ¿Podrían extraer de esa variable información agronómica más transferible (ej. agregaciones por zona, características del suelo asociadas)?

Definan sus umbrales de clasificación con criterio de negocio, y contrástenlos contra su propia distribución

Por qué importa: Dividir TCH o %Sac.Caña en terciles puros garantiza clases balanceadas, pero las fronteras resultantes pueden ser arbitrarias desde el punto de vista agronómico. El Ingenio maneja, como referencia orientativa, rangos aproximados como los siguientes:

Variable	Bajo	Medio	Alto
TCH (t/ha)	< 125	125–150	> 150
%Sac.Caña	< 12.2	12.2–12.9	> 13

Recomendación: Usen esto como una hipótesis de referencia a **contrastar contra la distribución real de su propio dataset** (percentil 25, mediana, percentil 75), no como un valor a copiar sin verificar — el histórico que ustedes tienen puede ser de años anteriores a mejoras recientes de productividad, así que sus propios rangos pueden diferir razonablemente. Documenten el criterio final que eligieron (percentiles puros, umbrales de negocio, o una combinación) y justifiquenlo.

Analicen la lluvia fraccionada por ventanas del ciclo, no solo el total

Por qué importa: El efecto fisiológico de la lluvia sobre el crecimiento de la caña (expansión celular, ganancia de peso) depende del momento del ciclo en que ocurre, no solo de la

cantidad total anual. Esto ha sido señalado explícitamente como un factor clave por la fuente del negocio.

Recomendación: Si su dataset trae variables de lluvia fraccionadas por ventana temporal (ej. lluvia de 0-3 meses, 3-6 meses, 6-9 meses, 2 meses antes de cosecha), inclúyanlas por separado en vez de colapsarlas en una sola variable anual, y analicen qué ventana pesa más para cada variable objetivo.

Documenten el rezago climático como una limitación (y, si tienen tiempo, explórenlo como feature)

Por qué importa: Existe un vacío real de variables climáticas en el histórico entre 2017 y comienzos de 2022 (antes de que el Ingenio integrara datos externos vía API) — esto **no es un dato faltante aleatorio**, es una limitación estructural de cobertura. Adicionalmente, fenómenos climáticos como El Niño/La Niña de un año pueden afectar la cosecha de años posteriores, no necesariamente la del mismo periodo, dado el ciclo de maduración de la caña.

Recomendación: Documenten explícitamente este vacío temporal como limitación de los datos (no lo traten como missing-at-random para efectos de imputación). Si el tiempo lo permite, planteen —aunque sea como pregunta de trabajo futuro si no logran implementarlo— si tendría sentido construir variables climáticas con rezago respecto a la fecha de siembra en vez de solo el periodo de cosecha.

Modelado

Sigan la progresión de lo simple a lo complejo, y no salten pasos

Por qué importa: Empezar con un modelo de referencia simple (regresión lineal, regresión logística) antes de pasar a modelos regularizados o más complejos les da una línea base honesta para saber si la complejidad adicional realmente aporta valor predictivo.

Recomendación: Reporten siempre el desempeño del modelo benchmark junto con el de los modelos más avanzados, y justifiquen la elección final no solo por la métrica, sino por interpretabilidad y estabilidad entre folds de validación cruzada.

Si implementan preprocesamiento "manual" (sin Pipeline), extremen el cuidado con el orden fit/transform

Por qué importa: Hacer imputación y escalado por fuera de un Pipeline es válido y a veces más claro pedagógicamente, pero aumenta el riesgo de aplicar .fit() sobre el conjunto de prueba por error, sobre todo cuando el notebook crece y hay que repetir pasos.

Recomendación accionable: Si optan por este enfoque, verifiquen explícitamente (con un comentario o assert) que cada fit() se llama solo sobre X_train.

Esperen que la clase "medio" sea la más difícil de clasificar, y tengan un plan para eso

Por qué importa: Cuando se categoriza por terciles, es un patrón muy frecuente que la clase intermedia obtenga precisión y recall notablemente peores que las clases extremas. Esto no es necesariamente un error de su código: es consecuencia esperable de que las fronteras entre clases contiguas sean estadísticamente arbitrarias y la clase "medio" limite con ambos extremos.

Pregunta para reflexionar: Si esto les ocurre, ¿el problema está en el modelo, en las variables predictoras, o en la definición misma de las clases? ¿Qué pasaría si probaran una definición de "medio" con un margen de separación más amplio, o con los umbrales de negocio mencionados arriba en vez de terciles exactos?

Validación

Comparen siempre el desempeño en validación cruzada contra el de prueba (hold-out)

Por qué importa: Esta comparación es la evidencia más directa de si su modelo generaliza bien o está sobreajustado. Un desempeño similar entre CV y test es una señal saludable; una diferencia grande indica sobreajuste.

Recomendación accionable: Repórtenla explícitamente en su informe como parte del análisis de resultados, no solo como un paso intermedio de código que se descarta.

Si usan regresión lineal, no se salten el diagnóstico de supuestos — y sean honestos con los resultados

Por qué importa: Verificar linealidad, homocedasticidad (Breusch-Pagan), normalidad de residuos (Shapiro-Wilk) e independencia (Durbin-Watson) les da información real sobre cuánto pueden confiar en los coeficientes y p-values del modelo.

Recomendación: Cuando un supuesto falle (es común, especialmente heterocedasticidad, dada la naturaleza agrícola de los datos), no se limiten a reportarlo. Discutan qué implica esto para la confiabilidad de sus conclusiones, y si les motiva a considerar transformaciones de la variable objetivo o modelos que no dependan de estos supuestos.

Elijan su métrica de evaluación pensando en el costo de negocio, no solo en la convención

Por qué importa: F1-weighted o accuracy son puntos de partida razonables, pero probablemente no capturan lo que realmente le importa al Ingenio (por ejemplo, no perderse lotes de "bajo" desempeño para poder intervenir a tiempo).

Pregunta para reflexionar: Si el costo de no detectar un lote "bajo" es mayor que el de una falsa alarma, ¿qué métrica (por ejemplo, el recall específico de la clase "bajo") debería pesar más al elegir su modelo final?

Tengan claro el alcance real de cada dataset antes de generalizar sus conclusiones

Por qué importa: El dataset usado para clasificación (BD_IPSA_1940) no es una muestra representativa de todo el Ingenio: fue construido intencionalmente con **solo las variedades**

más representativas, y solo suertes maduras químicamente y cosechadas mecánicamente. El dataset de regresión (HISTORICO_SUERTES), en cambio, incluye una población más amplia (maduradas y no maduradas, mecánica y manual). Esto ha sido confirmado directamente por quien construyó los datasets. **Recomendación:** En su informe, sean explícitos sobre esta diferencia de alcance. Cualquier conclusión de sus modelos de clasificación aplica, estrictamente, a lotes con esas características específicas (variedades principales + maduración química + cosecha mecánica) — no la presenten como si describiera el comportamiento de todo el Ingenio.

Comunicación de Resultados / Dominio del Negocio

Traduzcan cada variable importante de su modelo a un argumento agronómico

Por qué importa: Un coeficiente o una importancia de variable sin interpretación de negocio es solo un número. La diferencia entre un buen informe y uno mediocre suele estar aquí.

Recomendación accionable: Para cada una de las variables más influyentes de su modelo final, escriban explícitamente por qué tiene sentido (o no) desde el punto de vista agronómico. Si algo no tiene sentido obvio, inclúyanlo también — es información valiosa tanto para el Ingenio como para validar su propio modelo.

No terminen su análisis en la métrica

Por qué importa: Es muy común (y una oportunidad perdida) cerrar una sección de resultados con "el modelo obtuvo un F1 de X" sin traducir eso en una recomendación operativa concreta.

Recomendación accionable: Practiquen completar, para cada resultado relevante, una frase del tipo: *"Esto significa que el Ingenio podría [acción concreta] para [beneficio operativo/económico específico]."* Si no logran completarla con algo específico, probablemente falta profundizar la interpretación de negocio antes de dar el resultado por cerrado.

Sean transparentes sobre las limitaciones de los datos en sus conclusiones

Por qué importa: Un informe que reconoce honestamente sus incertidumbres (vacíos temporales en variables climáticas, alcance limitado del dataset de clasificación, variables cuyo significado no se pudo confirmar con certeza) demuestra más rigor profesional que uno que aparenta una limpieza y comprensión perfectas de los datos.

Recomendación accionable: Incluyan una sección breve de limitaciones que mencione explícitamente estos puntos, junto con cómo podrían abordarse en una siguiente iteración del proyecto.

Con respecto a variables climáticas

No usen la media/mediana del histórico completo para imputar climáticas

Por qué: Si el 75%+ de los nulos corresponde a un periodo entero sin medición (pre-2022), imputar con la media global inventa un clima "promedio" para años que pueden haber tenido condiciones muy distintas (recuerden que hasta se mencionaron fenómenos de El Niño/La Niña en esos años).

Alternativas a evaluar (comparen resultados, no elijan a ciegas):

- **Restringir el análisis climático solo al subconjunto con cobertura real** (ej. desde 2022 en adelante) y tratarlo como un modelo/análisis complementario, aceptando la reducción de tamaño muestral.
- **Crear una variable binaria "tiene_dato_climatico"** además de imputar, para que el modelo pueda distinguir registros con clima medido vs. inferido.
- Si van a imputar sobre todo el histórico de todas formas, opten por algo más razonado que la media global: por ejemplo, la media *por zona y por mes*, documentando que es una aproximación, no un dato real.

No descarten lluvias (ni otras variables climáticas) solo por correlación de Pearson baja

Qué hacer en su lugar, en orden de sencillez creciente:

1. Grafiquen TCH o %Sac.Caña en bins/cuantiles de la variable climática (ej. boxplot de TCH por deciles de lluvia) — esto revela relaciones no lineales que Pearson no ve.
2. Calculen `mutual_info_regression` (para TCH) o `mutual_info_classif` (para las categorías) desde `sklearn.feature_selection`, y compárenlo con la correlación lineal.
3. Si usan un modelo de árboles en algún punto del taller, revisen la importancia de esa variable ahí, aunque su correlación lineal haya sido baja.

Regla de decisión: solo descarten una variable climática si es consistentemente poco informativa en al menos dos de estos tres chequeos, no solo en el correlograma inicial.

FAQ Guía

1. ¿Por qué mi modelo de regresión da un R^2 sospechosamente alto (>0.95)?

Antes de celebrar, revisen si dejaron en el conjunto de predictores alguna variable que se calcule *a partir de* o *simultáneamente con* la variable objetivo (ej. rendimientos promedio, toneladas de azúcar, indicadores de extracción). Pregúntense: ¿esta variable estaría disponible si quisiera predecir el TCH de un lote *antes* de cosecharlo? Investiguen el

concepto de data leakage y, específicamente, la diferencia entre "variables leakage" (conocidas después del evento) y "variables proxy legítimas" (conocidas antes).

2. ¿Cómo decido qué variables descartar por ser "identificadores"?

No solo columnas obviamente tipo ID (nombre, código único). Piensen también en variables categóricas de muy alta cardinalidad que podrían estar actuando como un identificador disfrazado (ej. código de finca/lote). Investiguen qué es el "cardinality leakage" o el riesgo de sobreajuste a variables categóricas con muchos niveles y pocas observaciones por nivel.

3. Tengo miles de outliers según IQR, ¿los elimino todos?

No hay una respuesta única correcta, pero sí un mal hábito: aplazar la decisión indefinidamente. Para cada variable pregúntense: ¿este outlier refleja una condición agronómica real (sequía, evento extremo) o un error de captura de datos? Revisen literatura sobre "outliers estructurales vs. outliers de error" antes de decidir eliminar, transformar (ej. winsorización) o mantener.

4. ¿En qué momento del pipeline debo calcular la media/mediana para imputar?

Reflexionen: si calculan la media sobre todo el dataset antes de dividir train/test, ¿esa media "sabe" algo del conjunto de prueba? Investiguen cómo `sklearn.pipeline.Pipeline` resuelve esto automáticamente y por qué el orden `fit` (solo en train) → `transform` (en train y test) es crítico también dentro de cada fold de validación cruzada.

5. ¿Por qué mi clasificador nunca acierta en la clase "medio"?

Es un patrón muy común cuando se categoriza por terciles. Piensen en el problema desde la geometría de los datos: los terciles crean fronteras arbitrarias, y la clase intermedia limita con ambas clases extremas, por lo que es la más fácil de confundir. Antes de buscar un modelo más complejo, pregúntense si el problema está en el modelo o en la definición de las categorías (¿terciles fijos, o umbrales con criterio agronómico/ROC como han hecho otros grupos?).

6. ¿Debo usar terciles exactos o puedo definir mis propios umbrales de "alto/medio/bajo"?

El enunciado pide crear niveles de desempeño, no necesariamente terciles matemáticamente exactos. Investiguen si existen criterios técnicos del sector azucarero (Cenicaña, literatura agroindustrial) para definir "alto", "medio" y "bajo" TCH o sacarosa, y evalúen el trade-off entre balance de clases (terciles) y relevancia de negocio (umbrales técnicos).

7. Mis supuestos de regresión lineal (homocedasticidad, normalidad) no se cumplen. ¿Descarto el modelo?

No necesariamente, pero sí deben discutirlo con honestidad. Pregúntense: ¿qué implica la heterocedasticidad para la confiabilidad de mis intervalos de confianza y p-values? ¿Debería

considerar transformar la variable objetivo (log, Box-Cox) o probar un modelo que no asuma estos supuestos? Investiguen cuándo conviene reportar un modelo lineal "imperfecto pero interpretable" frente a uno más flexible.

8. ¿Cómo elijo entre Ridge y Lasso (o entre varios modelos con métricas similares)?

No se queden solo en "cuál tiene menor RMSE/mayor F1". Consideren también: ¿qué modelo es más interpretable para el Ingenio? ¿Cuál generaliza mejor entre folds (menor varianza en CV)? ¿Lasso, al hacer selección de variables, revela algo agronómicamente interesante que Ridge no muestra?

9. Tengo muchas variables con correlación baja individual con el objetivo (<0.3). ¿Son inútiles?

No necesariamente. La correlación lineal simple no captura interacciones ni relaciones no lineales. Investiguen técnicas como importancia de variables en modelos de árboles, o análisis de interacción (ej. lluvias $\times$ variedad), antes de descartar una variable solo por su correlación univariada baja.

10. ¿Qué hago si mi variable objetivo tiene una distribución muy concentrada (poca dispersión, ej. sacarosa entre 11-13%)?

Antes de asumir que "es fácil de predecir", pregúntense si esa poca dispersión hace que errores pequeños en términos absolutos representen errores grandes en términos relativos/de negocio. ¿Qué tan sensible es la decisión operativa del Ingenio a diferencias de 0.5 puntos de sacarosa?

11. ¿Cómo interpreto que una variable categórica (como la finca o el código de lote) sea la más "importante" en mi modelo?

Es una señal ambigua: puede reflejar un efecto real de manejo/microclima por finca (información valiosa), o puede ser el modelo memorizando el histórico de ese lote específico (sobreajuste). Pregúntense cómo evaluarían la capacidad de su modelo de generalizar a un lote completamente nuevo, no visto en entrenamiento.

12. ¿Qué métrica de clasificación debo priorizar si tengo 3 clases desbalanceadas o de similar tamaño pero con distinto costo de negocio?

No hay una métrica universalmente "correcta". Investiguen la diferencia entre accuracy, F1 macro, F1 weighted, y métricas por clase (precision/recall específicos de "bajo", por ejemplo). Pregúntense: para el Ingenio, ¿es más costoso no detectar un lote de bajo desempeño (falso negativo en "bajo") o clasificar erróneamente uno bueno como problemático (falso positivo)?

13. Mi informe reporta buenas métricas pero no sé cómo conectar esto con una recomendación para el Ingenio. ¿Cómo lo hago?

Practiquen completar la frase: "Dado que el modelo identifica que [variable X] es el predictor más influyente de [TCH/sacarosa], el Ingenio podría [acción concreta de manejo agronómico]". Si no logran completar esa frase de forma específica, probablemente falta profundizar la interpretación agronómica de sus resultados, no solo el ajuste estadístico.

14. ¿Es necesario calcular VIF si ya voy a usar Ridge/Lasso?

Reflexionen: la regularización mitiga *algunos* problemas de multicolinealidad para efectos de predicción, pero ¿sigue siendo válida la interpretación de coeficientes individuales cuando hay multicolinealidad alta? Investiguen la diferencia entre "modelo útil para predecir" y "modelo útil para interpretar causalmente" en presencia de variables correlacionadas.

15. ¿Cómo sé si mi ingeniería de características agrega valor real, o solo complejidad?

Comparen el desempeño del modelo con y sin cada característica nueva, usando siempre el mismo esquema de validación cruzada. Pregúntense también: ¿la nueva variable tiene sentido agronómico independiente, o es una recombinación de variables que ya están en el modelo (y por tanto no aporta información nueva, solo colinealidad adicional)?

16. Si tengo una variable con fundamento agronómico fuerte pero correlación baja en mis datos, ¿la descarto?

No necesariamente, y esto ya no es solo una precaución teórica: es algo que ocurrió literalmente en la sesión con la creadora de los datos. Antes de descartarla, pregúntense: ¿el rango de valores en mi dataset es lo suficientemente amplio para que el efecto se manifieste? ¿La relación podría ser no lineal? Investiguen `mutual_info` o importancia en modelos de árboles como complemento a la correlación de Pearson antes de tomar la decisión final, y documenten su razonamiento explícitamente en el informe.